Proyecto de investigación:
Prácticas 1 y 2

UNIVERSIDADE DA CORUÑA

Grupo 1

Laura Fernández Castelo

Marta Bao Gomes

Ana Gómez Roel

Inteligencia Computacional para Bioinformática

Índice

1 Análisis previo de los datos **4**

1.1 Conjunto de datos: Iris [1] 4

1.1.1 Medidas 4

1.1.2 Gráficos 4

1.2 Conjunto de datos: QSAR *biodegradation* [2] 6

2 Primera fase: preprocesado de datos **6**

2.1 Preparación de los datos 6

2.2 Normalización de los datos 6

3 Segunda fase: aprendizaje **6**

3.1 Configuración del método de aprendizaje 6

3.2 Selección del método de estimación del error real 6

3.3 Elección de las métricas de evaluación de error 7

3.4 Entrenamiento y obtención de resultados para cada modelo 7

4 Análisis de resultados y comparación de modelos **8**

4.1 Selección de la métrica de evaluación del error 8

4.2 Tabla de resultados para los modelos implicados 8

4.2.1 Conjunto de datos Iris 8

4.2.2 Conjunto de datos QSAR 9

4.3 Diagrama de cajas y bigotes 11

4.3.1 Conjunto de datos Iris 11

4.3.2 Conjunto de datos QSAR 12

4.4 Aplicación de test de comparación múltiple 12

4.4.1 Conjunto de datos Iris 13

4.4.2 Conjunto de datos QSAR 13

4.5 Selección del mejor modelo para la resolución del problema 14

4.5.1 Conjunto de datos Iris 14

4.5.2 Conjunto de datos QSAR-biodeg 14

5 Conclusiones **15**

6 Anexos **16**

6.1 Anexo 1: Código en R para análisis de datos 16

7 Bibliografía **17**

Índice de figuras

1 Histogramas de Iris. 5

2 Boxplot de Iris. 5

3 Mejor árbol de decisión de Iris. 9

4 Mejor árbol de decisión de QSAR. 10

5 Boxplots de F1-Score en Iris. 11

6 Boxplots de F1-Score de QSAR. 12

7 Kruskal-Wallis de Iris. 13

8 ANOVA de Qsar. 13

9 Comparación múltiple de QSAR. 14

Índice de tablas

1 Medidas de tendencia central y dispersión de las variables del conjunto de datos IRIS. . . 4

2 Resultados del conjunto de datos Iris. 8

3 Resultados del conjunto de datos QSAR-biodeg. 9

1 Análisis previo de los datos

1.1 Conjunto de datos: Iris [1]

El conjunto de datos de Iris está formado por 150 muestras de las cuales se conocen 4 características: longitud y anchura del sépalo (variables 1 y 2 respectivamente), y longitud y anchura del pétalo (variables 3 y 4 respectivamente). Cada muestra pertenece a una de tres especies de Iris: setosa, versicolor y virgínica. Se trata de un dataset balanceado, en el que hay 50 observaciones para cada especie de Iris.

1.1.1 Medidas

Se calcularon las medidas de tendencia central (media, mediana y moda) y de dispersión (desviación estándar, varianza y rango), así como también se calcularon los valores de asimetría y curtosis para cada una de las cuatro variables o características morfológicas estudiadas. Estos datos aparecen recogidos en la tabla 1.

Medida	Variable 1	Variable 2	Variable 3	Variable 4
Media	5.843	3.054	3.759	1.199
Mediana	5.800	3.000	4.350	1.300
Moda	5.000	3.000	1.500	0.200
Desviación estándar	0.828	0.434	1.764	0.763
Varianza	0.686	0.188	3.113	0.582
Rango	3.600	2.400	5.900	2.400

Tabla 1: Medidas de tendencia central y dispersión de las variables del conjunto de datos IRIS.

1.1.2 Gráficos

A continuación, se muestran los histogramas y boxplots obtenidos a partir de las variables del conjunto de datos Iris. Se usó el lenguaje de programación R para obtener los ambos. En el Anexo 1 está disponible el código usado.

Los histogramas de la figura 1 permiten observar que las especies de Iris presentan diferencias en sus características morfológicas, especialmente en las variables 3 y 4. En ellas es donde dichas diferencias son mayores, estando setosa completamente separada de versicolor y virgínica.

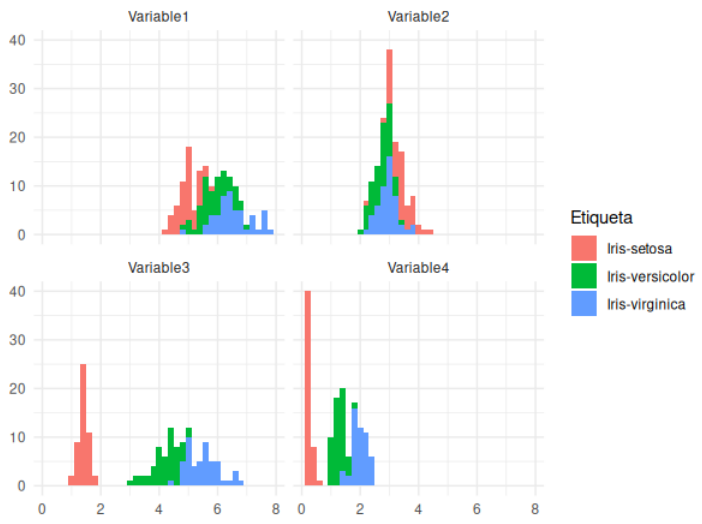

Figura 1: Histogramas de Iris.

En el boxplot de la figura 2 es posible visualizar la variabilidad y dispersión de los datos para cada especie. En particular, se pueden observar diferencias marcadas en las medianas y los rangos intercuartílicos de las variables analizadas. Especialmente en las variables 3 y 4, existe una mayor diferencia entre las 3 especies, destacando la de setosa, que se encuentra completamente separada de las otras dos.

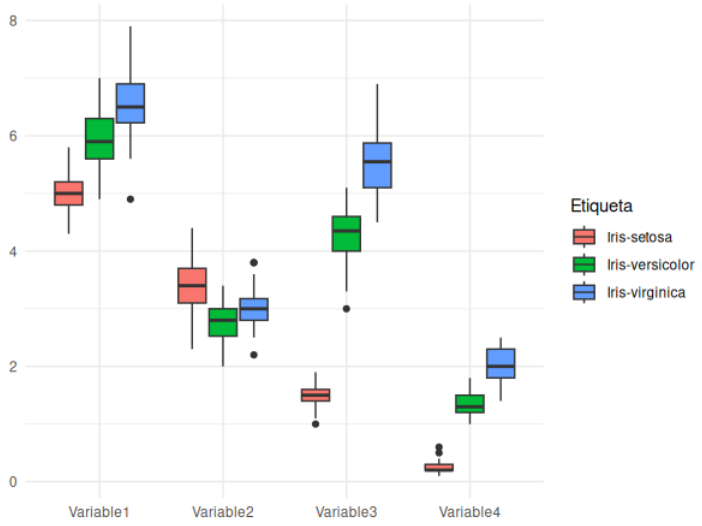

Figura 2: Boxplot de Iris.

Al observar los histogramas y los boxplots, por un lado, cabe esperar que los modelos que se elaboren sean capaces de etiquetar prácticamente sin errores aquellos datos que pertenezcan a la variable setosa. Por otro lado, es posible que esto no sea así con versicolor y virgínica, ya que los datos no muestran tantas diferencias entre una especie y otra y están parcialmente solapados.

1.2 Conjunto de datos: QSAR *biodegradation* [2]

El conjunto de datos QSAR está formado por 1055 muestras, para cada una de las cuales se conocen 41 atributos moleculares que permiten clasificar distintos químicos en dos clases: RB y NRB (listos y no listos para ser biodegradados, respectivamente). Este conjunto de datos no está balanceado, dado que recoge 356 muestras de RB y 699 de NRB.

2 Primera fase: preprocesado de datos

2.1 Preparación de los datos

Los datos han sido recopilados de dos datasets del UCI: Machine Learning Repository: “Iris” y “QSAR Biodegradation”. No se ha realizado limpieza de valores faltantes o eliminación de ruido, ya que los datos no lo requerían.

Además, tampoco es necesario la recodificación de ninguna variable, ya que, en ambos conjuntos de datos las únicas categóricas son las etiquetas y los tres modelos empleados en las prácticas 1 y 2 (discriminante lineal, discriminante cuadrático y árboles de decisión) no se ven influidos por el uso de este tipo de datos.

2.2 Normalización de los datos

Se aplica una estandarización a las variables de entrada en ambos conjuntos, mediante la función `normalize`, que lo aplica independientemente a cada una de ellas. Este método puede ayudar a mejorar el rendimiento ciertos modelos al asegurar que todos los datos están en la mismo orden de magnitud. Cabe destacar que esta transformación no va tener influencia en los árboles de decisión, debido a que estos no se ven afectados por la presencia de variables de entrada con órdenes de magnitud diferentes.

3 Segunda fase: aprendizaje

3.1 Configuración del método de aprendizaje

Se emplearon diferentes enfoques de aprendizaje mediante modelos discriminantes, tanto lineales como cuadráticos. Asimismo también se han utilizado tres árboles de decisión cuyas características se explicarán más adelante.

3.2 Selección del método de estimación del error real

Para ambos conjuntos de datos, Iris y QSAR, y todos los modelos se adoptó la validación cruzada k-fold con k=10 para estimar el error real. Este enfoque, muy empleado en aprendizaje automático, consiste

en dividir los datos en 10 particiones (o *folds*). En cada iteración, el modelo se entrena con 9 de estos subconjuntos y se evalúa en el restante, de forma que cada partición cumple una vez la función de conjunto de prueba.

3.3 Elección de las métricas de evaluación de error

Para medir la efectividad de los modelos de clasificación entrenados con los conjuntos de datos Iris y QSAR, se optó por emplear diversas métricas de evaluación del error. Estas permiten examinar en detalle distintos aspectos del rendimiento del modelo, proporcionando una visión más completa de su desempeño. Las métricas calculadas fueron:

- Accuracy
- F1-score
- Precision
- Recall
- Specificity
- Negative Predictive Value (NPV)

3.4 Entrenamiento y obtención de resultados para cada modelo

En primer lugar, se utilizó el modelo lineal basado en la regresión lineal, que presupone una relación directa entre las variables de entrada y la variable de salida.

En segundo lugar, se usarán modelos cuadráticos, que son similares a los anteriores, pero las fronteras de las regiones de decisión son superficies cuadráticas. En concreto, se ha usado el parámetro 'pseudoQuadratic', el cual es más estable al evitar problemas con la inversión de matrices. Esto se debe a que 'pseudoQuadratic' usa la pseudoinversa cuando la matriz de covarianza de una clase no es invertible [3].

Por último, también se han realizado para ambos conjuntos de datos tres árboles de decisión, variando entre ellos uno de sus parámetros. La función `fitctree` permite modificar, entre otros, los siguientes:

- `MaxNumSplits`: establece la profundidad máxima que puede alcanzar el árbol. Se han usado como valores 10, 15 y 20 para los tres árboles, respectivamente.
- `MinLeafSize`: establece el número mínimo de observaciones de un nodo hoja. Se ha establecido 1 como valor para los tres árboles.
- `MinParentSize`: establece el número mínimo de observaciones que debe tener un nodo padre. Se ha establecido 10 como valor para los 3 árboles.

Cabe destacar que se ha dedicido modificar únicamente uno de los parámetros entre los distintos árboles (`MaxNumSplits`), ya que esto permitirá una mayor interpretación al discutir las diferencias de

resultados. Al mantenerse constantes `MinLeafSize` y `MinParentSize`, las diferencias en el rendimiento de los modelos se deben exclusivamente al cambio de profundidad del árbol (`MaxNumSplits`), pudiendo evaluar su impacto de forma aislada. [4].

4 Análisis de resultados y comparación de modelos

4.1 Selección de la métrica de evaluación del error

Para evaluar el error de ambos conjuntos de datos, se escogió la métrica F1-Score. Esta medida se calcula a partir de la siguiente ecuación:

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{1}$$

Permite combinar las métricas Precision y Recall en una sola. Esto es especialmente útil en conjuntos de datos que estén desbalanceados, como el conjunto de datos QSAR. Por ello, el F1-Score es una métrica útil para evaluar la calidad de los modelos evitando sesgos por desbalances en la distribución de las clases.

4.2 Tabla de resultados para los modelos implicados

En este apartado se presentan los resultados de los modelos obtenidos de los conjuntos de datos Iris y QSAR-biodeg.

4.2.1 Conjunto de datos Iris

Iris	**Lineal**	**Cuadrático**	**Árbol1**	**Árbol2**	**Árbol3**
Media	0.980	0.966	0.946	0.940	0.934
Desviación	0.041	0.076	0.104	0.104	0.104

Tabla 2: Resultados del conjunto de datos Iris.

Las conclusiones obtenidas a partir de los resultados presentados en la tabla 2 son las siguientes:

El modelo lineal presenta el mayor rendimiento promedio, con una media de 0.980 y una desviación de 0.041. Este desempeño superior, junto con la baja variabilidad, indica que el modelo lineal posee una buena capacidad de generalización y es menos sensible a las fluctuaciones en los datos.

El modelo cuadrático, con una media de 0.966 y una desviación de 0.076, muestra un rendimiento cercano al del modelo lineal. No obstante, la mayor variabilidad sugiere que este modelo es ligeramente más sensible a las características particulares de cada subconjunto de datos, lo cual podría afectar su estabilidad en determinadas condiciones.

Por otro lado, los modelos basados en árboles (Árbol1, Árbol2 y Árbol3) presentan medias inferiores

(0.946 y 0.940) y desviaciones que oscilan entre 0.041 y 0.104. Esto refleja que, en el conjunto de datos Iris, estos modelos tienen un rendimiento inferior y una mayor dispersión en sus resultados.

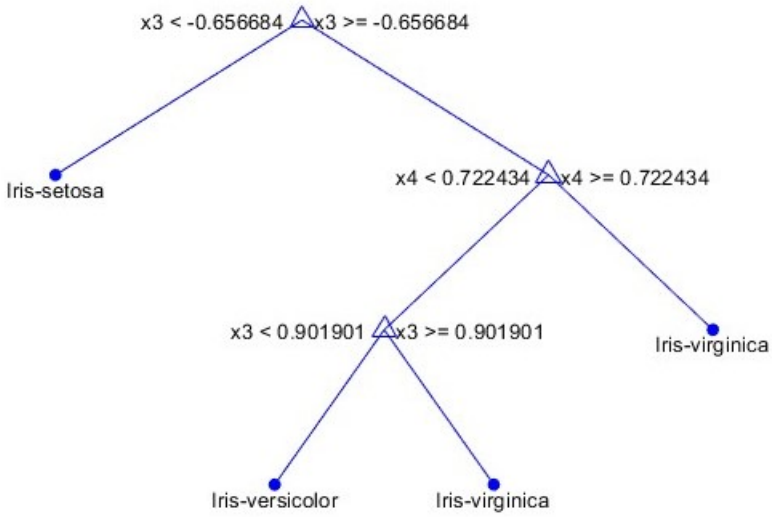

Figura 3: Mejor árbol de decisión de Iris.

En la figura 3 se puede observar el Árbol 1, se ha escogido este como mejor árbol por tener ligeramente mejores resultados.

En conclusión, para el conjunto de datos Iris, los modelos lineal y cuadrático ofrecen resultados más consistentes y precisos, mientras que los modelos basados en árboles muestran una mayor sensibilidad a la variabilidad del conjunto, lo que podría limitar su efectividad sin una adecuada optimización.

4.2.2 Conjunto de datos QSAR

QSAR-biodeg	Lineal	Cuadrático	Árbol1	Árbol2	Árbol3
Media	0.838	0.780	0.789	0.786	0.782
Desviación	0.069	0.053	0.070	0.074	0.083

Tabla 3: Resultados del conjunto de datos QSAR-biodeg.

Las conclusiones obtenidas a partir de los resultados obtenido en la tabla 3 son las siguientes:

El modelo lineal presenta el mejor desempeño, alcanzando una media de 0.838 con una desviación de 0.069. Este resultado indica que el enfoque lineal ofrece una buena capacidad de generalización y un comportamiento relativamente estable frente a las variaciones en el conjunto de datos.

El modelo cuadrático, con una media de 0.780 y una desviación de 0.053, muestra un rendimiento inferior en comparación con el modelo lineal. Aunque la menor desviación sugiere una mayor estabilidad, su rendimiento promedio resulta menos competitivo, lo cual puede limitar su efectividad en aplicaciones prácticas.

Los modelos basados en árboles (Árbol1, Árbol2 y Árbol3) presentan medias intermedias (entre 0.786 y 0.789) y desviaciones que oscilan entre 0.070 y 0.083. Esto refleja que, en este contexto, estos

modelos tienen un desempeño similar al del enfoque cuadrático, pero con una mayor variabilidad en los resultados.

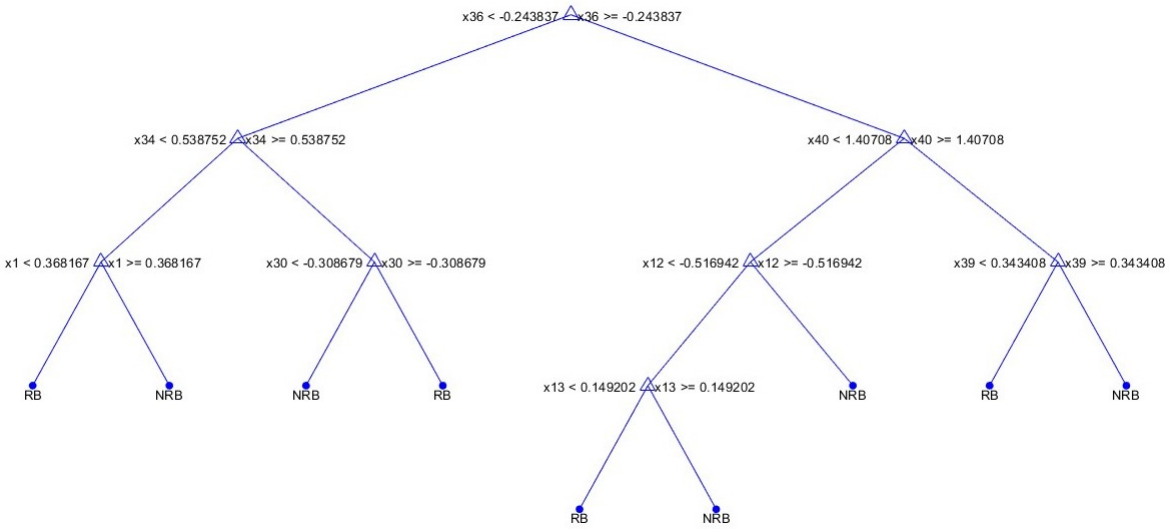

Figura 4: Mejor árbol de decisión de QSAR.

En la figura 4 se puede observar el Árbol 1, el cual ha sido escogido como mejor árbol por tener ligeramente mejores resultados.

En conclusión, para el conjunto de datos QSAR-biodeg el modelo lineal destaca por su mayor precisión, mientras que los modelos cuadrático y basados en árboles presentan resultados inferiores, destacando este último por una mayor dispersión en sus resultados.

4.3 Diagrama de cajas y bigotes

4.3.1 Conjunto de datos Iris

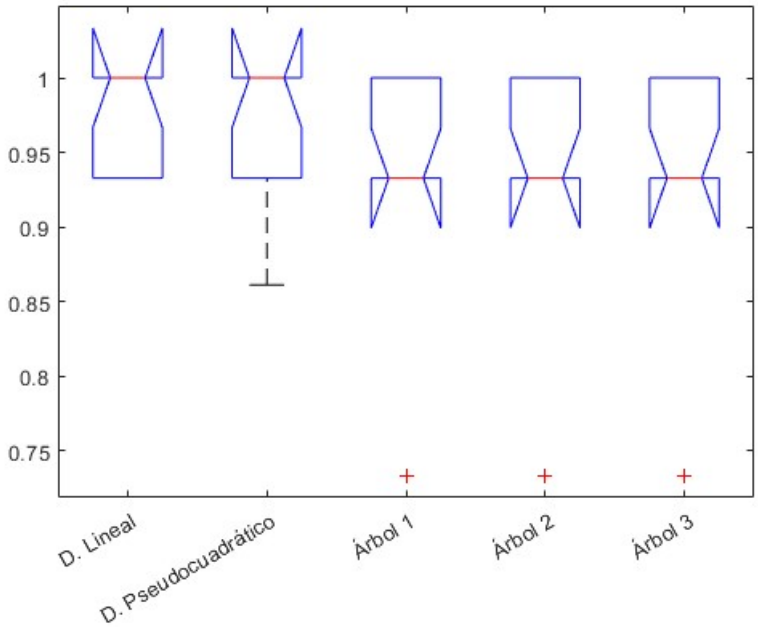

Figura 5: Boxplots de F1-Score en Iris.

En la figura 5 se observa que tanto el modelo lineal como el pseudocuadrático presentan distribuciones similares, con medianas y rangos intercuartílicos muy próximos. Por otro lado, los modelos de árboles mantienen características semejantes entre sí, lo que lleva a la conclusión de que los ajustes realizados, en concreto en el parámetro maxdepth, no han tenido un impacto significativo en sus resultados.

Es importante destacar que cada uno de los modelos basados en árboles exhiben un valor atípico extremo, respectivamente. Lo que podría estar influyendo en gran medida en las medias de F1-Score.

4.3.2 Conjunto de datos QSAR

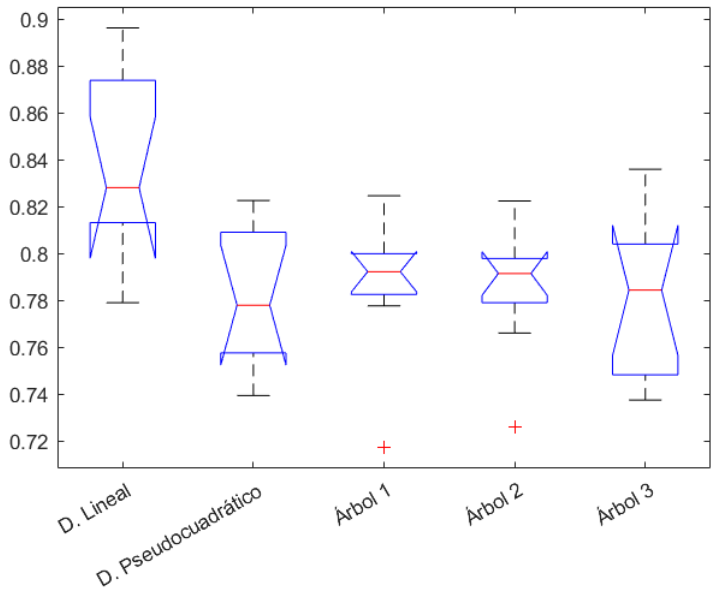

Figura 6: Boxplots de F1-Score de QSAR.

En la figura 6 se puede observar que el método lineal muestra una distribución más amplia en comparación con los demás, lo que sugiere una mayor variabilidad en sus resultados. El modelo pseudocuadrático presenta una mediana más baja y una dispersión intermedia, indicando menor variabilidad pero también menor rendimiento.

Los tres árboles de decisión muestran medianas similares, aunque con ligeras diferencias en la dispersión. Además, tanto el árbol 1 como el 2 presentan cada uno un valor atípico.

En términos generales, el modelo lineal presenta una mayor mediana y ausencia de valores atípicos extremos por lo que parece ser el mejor modelo aplicado.

4.4 Aplicación de test de comparación múltiple

Es importante destacar que se ha elegido como valor crítico 0,05, lo que implica que las comparaciones entre los modelos se han realizado con un nivel de confianza del 95 %.

4.4.1 Conjunto de datos Iris

Kruskal-Wallis ANOVA Table

Source	SS	df	MS	Chi-sq	Prob>Chi-sq
Columns	610.05	4	152.512	3.57	0.4676
Error	7767.45	45	172.61		
Total	8377.5	49			

Figura 7: Kruskal-Wallis de Iris.

En la figura 7 podemos observar que el resultado del test estadístico es no significativo, al obtener un valor mayor de 0.05. Es decir, no se obtuvieron diferencias estadísticas entre los modelos analizados. Dado que no existen diferencias, según el principio de parsimonia, se debe escoger el modelo que sea más simple. Por ello, se concluye que el modelo lineal es el más adecuado para predecir el conjunto de datos de Iris.

4.4.2 Conjunto de datos QSAR

ANOVA Table

Source	SS	df	MS	F	Prob>F
Columns	0.02395	4	0.00599	5.69	0.0009
Error	0.04737	45	0.00105		
Total	0.07132	49			

Figura 8: ANOVA de Qsar.

En la figura 8 podemos observar que el resultado del test estadístico es significativo, al obtener un valor menor de 0.05. Es decir, se obtuvieron diferencias estadísticas entre los modelos analizados. A continuación, se procedió a realizar un análisis de comparación múltiple para discernir entre qué modelos se observaron estas diferencias.

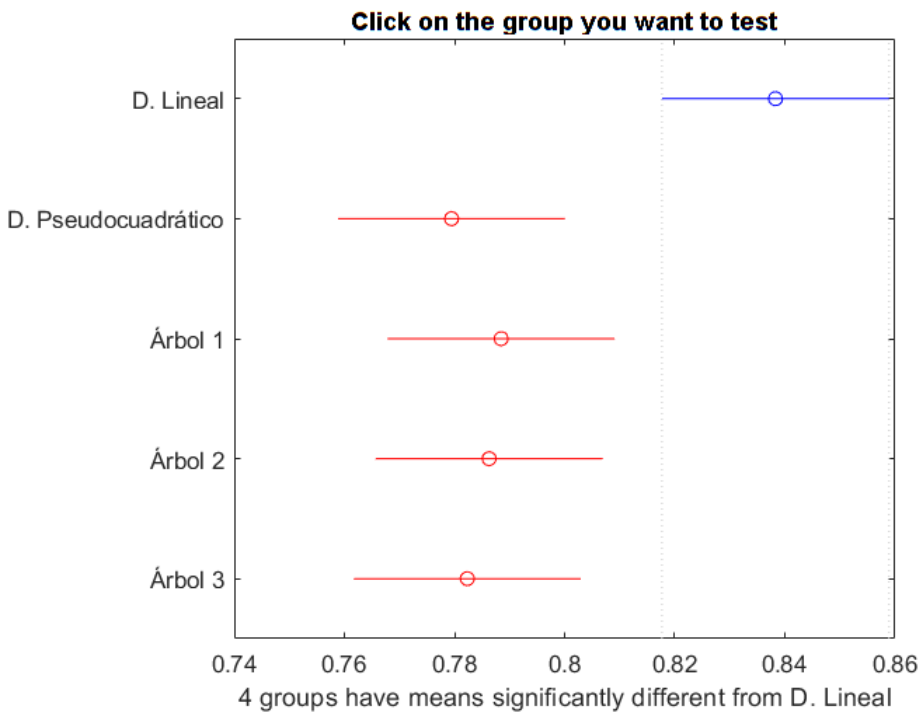

Figura 9: Comparación múltiple de QSAR.

En la figura 9 podemos observar que existen diferencias estadísticamente significativas entre el modelo lineal y el resto de los modelos analizados. Esto reafirma que el modelo lineal es el que presenta mejores datos de F1-Score.

4.5 Selección del mejor modelo para la resolución del problema

En base al análisis que se ha realizado, se puede concluir que el modelo lineal es la opción más adecuada para abordar ambos conjuntos de datos propuestos, tanto por los resultados obtenidos como por el principio de parsimonia, que sugiere que no se debe complicar innecesariamente el modelo cuando una solución más sencilla puede ser igualmente efectiva, favoreciendo el uso de un modelo lineal.

4.5.1 Conjunto de datos Iris

En este conjunto de datos, el modelo lineal presentó la mayor media (0.980) junto con una baja variabilidad (desviación de 0.041). Estos resultados son apoyados por el test de Kruskal-Wallis, el cual afirmó que efectivamente el enfoque lineal era el más adecuado para el conjunto de datos.

4.5.2 Conjunto de datos QSAR-biodeg

En este conjunto de datos el modelo lineal volvió a mostrar el desempeño más destacado, alcanzando una media de 0.838 con una desviación de 0.069, superando a los demás modelos calculados. Estos

resultados son apoyados por tests estadísticos (como ANOVA y la comparación múltiple), reforzando la consistencia del enfoque lineal.

5 Conclusiones

El análisis realizado a lo largo de este trabajo permitió comparar distintos modelos aplicados a dos conjuntos de datos representativos: Iris y QSAR-biodeg. Los resultados que se han obtenido muestran que el modelo lineal evidencia medias más altas y desviaciones más bajas en ambos conjuntos de datos.

Las representaciones gráficas (boxplots, test de Kruskal-Wallis, ANOVA y comparaciones múltiples) complementaron los hallazgos anteriormente expuestos.

Además, el principio de parsimonia reafirma estas conclusiones al ser el modelo lineal el más simple de los aplicados.

En conclusión, los hallazgos obtenidos sugieren que la estrategia lineal proporciona una mayor precisión, y además garantiza una menor sensibilidad a los cambios de datos.

6 Anexos

6.1 Anexo 1: Código en R para análisis de datos

En este anexo se presenta el código utilizado en R para generar los diagramas de cajas y bigotes e histogramas del apartado de análisis previos:

```
library(tidyverse)
iris <- read.csv("iris/iris.data")
qsar <- read.csv("qsar+biodegradation/biodeg.csv", sep=";")

colnames(iris) <- c("Variable1", "Variable2", "Variable3", "Variable4", "Etiqueta")
iris2 <- pivot_longer(iris, Variable1:Variable4, names_to = "Columna", values_to = "
    Valores")

ggplot(iris2, aes(x = Columna, y = Valores, fill = Etiqueta)) +
  geom_boxplot() + labs(y ="", x="") +
  theme_minimal()

ggplot(iris2, aes(x  = Valores, fill = Etiqueta)) +
  geom_histogram(bins = 40) + facet_wrap(~Columna) + labs(y ="", x="") +
  theme_minimal()

qsar2 <- pivot_longer(qsar, X3.919:X0.11, names_to = "Variable", values_to = "Valores")
qsar3 <- pivot_longer(qsar, X1.201:X0.24, names_to = "Variable", values_to = "Valores")

ggplot(qsar2, aes(x = RB, y = Valores, fill = RB)) +
  geom_boxplot() + facet_wrap(~Variable, scales = "free") +
  theme_minimal()

ggplot(qsar2, aes(x  = Valores, fill = Etiqueta)) +
  geom_histogram(bins = 40) + facet_wrap(~Columna) +
  theme_minimal()
```

7 Bibliografía

[1] D. Dua y C. Graff. *UCI Machine Learning Repository: Iris Data Set*. Retrieved July 9, 2024. 2019. URL: https://archive.ics.uci.edu/dataset/53/iris.

[2] Kamel Mansouri et al. *QSAR biodegradation*. UCI Machine Learning Repository. 2013. URL: https://doi.org/10.24432/C5H60M.

[3] The MathWorks, Inc. *Improving Discriminant Analysis Models*. https://es.mathworks.com/help/stats/improving-discriminant-analysis-models.html. Accessed: 14 March 2025.

[4] Inc. The MathWorks. *Statistics and Machine Learning Toolbox: Reference*. The MathWorks, Inc. Natick, Massachusetts, 2025. URL: https://es.mathworks.com/help/stats/fitctree.html.